

AI 驱动文献自动化检索与知识库构建项目任务书

为了大幅提升我们在科研项目（如生物光子学、OCT 技术应用等领域）中的文献调研效率，现启动“文献自动化检索与知识库构建” workflow 开发项目。本项目旨在利用 AI 与自动化工具，将繁琐的“搜索-筛选-下载-整理”过程转化为全自动的生产力流水线。

一、项目核心目标

开发一套自动化的 workflow，能够根据指定的关键词，自动从各大数据库检索文献，利用大模型评估相关性，并自动下载、打包，最终为 NotebookLM 知识库的建立提供标准化的文档包。

二、功能需求与技术指标

1. 自动化检索与抓取（核心）

- **目标数据源：** 中国知网（CNKI）、Google Scholar、学术博客、专利网站等。
- **功能要求：** 根据输入的检索词（例如：“生物光子学应用”、“OCT 在线测量”等），自动获取文献或文章的元数据及下载链接。
- **技术建议：** 结合同学们已部署的 OpenClaw，利用 n8n 或 Coze 搭建自动化流程。

2. AI 智能相关性筛选

- **功能要求：** 抓取到文献摘要或全文后，自动调用大语言模型（LLM）API 进行文本分析，与设定的研究主题进行相关性比对。
- **判定标准：** 设定相关性阈值（如大于 70%）。仅保留达到阈值的文献。
- **模型建议：** 考虑到调用成本，建议接入 DeepSeek、通义千问或 Kimi 的 API 进行批量处理。

3. 自动化下载与文档处理

- **格式统一：** 将筛选出的高相关性文献统一保存为 PDF 格式（若为网页或博客，需自动转换为 PDF）。
- **智能打包：** 将下载的多个 PDF 自动合并。为了适配知识库的容量限制，合并后的单个 PDF 文档大小必须严格控制在 160MB 以内。

4. 知识库对接（进阶/探索项）

- **终极目标：** 探索能否通过 API 或 RPA（机器人流程自动化）方式，将打包好的 PDF 自动上传至 NotebookLM。
- **保底方案：** 若自动化上传 NotebookLM 的接口成本过高或技术壁垒过大，此步骤可降级为“自动将合并后的 PDF 输出到指定云盘文件夹，由人工手动导入 NotebookLM”。

三、参考工具箱（仅供启发，不作强制限制）

前期经过初步调研，收集了以下工具和方案供大家在技术选型时参考。你们可以自由组合、尝试，找到最稳定、高效的路径：

- **节点与爬虫技能：** Scrapling（擅长复杂爬虫）、Find-news（为 AI 提供实时联网浏览能力）、Firecrawl（可无损抓取任意网站并转为 Markdown）、instant data scraper（轻量级网页结构爬取）。
- **文献管理与专用插件：** Zotero 及其 AI 插件、QoderWork（结合终端环境配置 papersearchmcp 批量下载）。
- **工作流引擎：** 充分利用 n8n 的自动化流转能力（处理 HTTP 请求、文件保存与 API 调用）或 Coze 的流程编排。

四、考核与交付物

1. **完整的工作流文件：** 例如 n8n 的 JSON 导出文件或代码脚本。
2. **项目说明文档：** 记录技术选型理由、API 接入方法、遇到的反爬限制及解决思路。
3. **实际运行演示：** 设定一个真实的科研课题，一键运行工作流，交付最终合并好且小于 160MB 的 PDF 文档集。

项目寄语： 这个项目没有标准答案，提供的参考工具只是起点。希望大家发挥“创业团队”般的极客精神，大胆假设，小心求证，用工程师的思维解决科研痛点。期待看到你们的解决方案！